Thinking to Recall: How Reasoning Unlocks Parametric Knowledge in LLMs

2026.03.17

발표자 : 홍성빈

목차

1. Background
2. Setup
3. Reasoning Expands The Model’s Parametric Knowledge Boundary
4. Question Complexity is a Poor Predictor of Reasoning Effectiveness
5. How Reasoning Improves Parametric Recall?
6. Case Studies
7. Conclusion

Background

기본적인 통념 : 다단계적 문제에서만 도움이 된다.

그러나 과연 다단계적 문제에서만 도움이 될까 ?

Setup

1. Model : Reasoning On/Off 전환 가능한 Hybrid model

Gemini-2.5-Flash

Gemini-2.5-Pro

Qwen3-32B

2. Dataset : Two challenging closed-book QA datasets

Simple QA-Verified

실제적인 질문
1,000개 예제 서브셋으로 90%가 단일 단계 질문

Entity Questions

사전 정의된 질문 템플릿 기반
4가지 관계 타입에서 각 250개씩 총 1,000개 샘플

3. Metric

pass@k

Setup

Gemini-2.5-Flash를 자동 평가자로 사용

+

Chen의 비편향 추정 방법 사용

예측 답변의 정확성 평가를 위해

n번 샘플링으로 모든 k 한번에 추정
→ 비용 절감 + 분산 감소 → 신뢰도 향상

Reasoning Expands The Model’s Parametric Knowledge Boundary

추론이 모델의 Parametric 지식 경계를 확장한다

Evaluate the potential of reasoning to improve parametric recall

두가지 가능성

경계 확장 : 추론이 추론 없이는 사실상 도달 불가능했던 정답 발견하게 만들어 줌

샘플링 효율 향상 : 추론이 이미 모델 정책 하에서 상대적으로 가능성이 높은 답변의 확률을 높일 뿐

Reasoning Expands The Model's Parametric Knowledge Boundary

추론이 모델의 Parametric 지식 경계를 확장한다

경계 확장 : 추론이 추론 없이는 사실상 도달 불가능했던 정답 발견하게 만들어 줌

추론 ON, OFF pass@k 곡선 비교

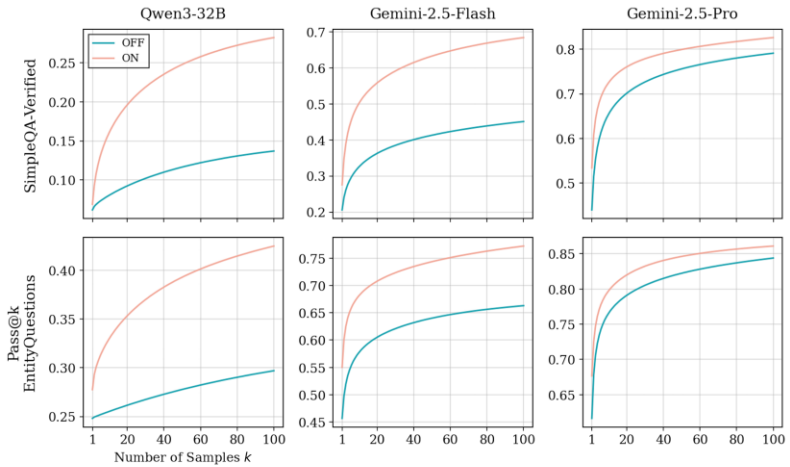

Figure 1 | Pass@k curves across two closed-book QA benchmarks and three LLMs, comparing the same models with reasoning OFF vs ON.

→ **추론이 모든 모델과 데이터셋에서 pass@k 값 일관되게 향상시킴**

→ **표준 정확도에서도 tangible한 향상이 있지만 높은 k 값에서 더욱 두드러짐**

→ **일부 경우, 추론 통해 pass@k 거의 두 배 (SimpleQA-Verified - Qwen3-32B)**

추론이 Parametric 회상 경계를 확장함을 시사

Reasoning Expands The Model's Parametric Knowledge Boundary

추론이 모델의 Parametric 지식 경계를 확장한다

Reasoning Effectiveness Measure : A Weighted Average Improvement

pass@k 곡선 세부적인 정보 제공 but, 단일 요약 metric(Ω)도 必

두가지 핵심 **추론 OFF 대비 효과 측정** **더 큰 k 값에 더 높은 중요도 부여**

$$\Omega(N) = \sum_{k=1}^{N} \left[\underbrace{k}_{\text{Linear Boundary Weight}} \cdot \underbrace{\frac{\text{pass@}k_{\text{ON}} - \text{pass@}k_{\text{OFF}}}{\text{pass@}k_{\text{OFF}}}}_{\text{Improvement in pass@k relative to OFF baseline}} \right] \cdot \underbrace{\frac{1}{\sum_{k'=1}^{N} k'}}_{\text{Normalization by sum of weights}}$$

k(선형 경계 가중치) : 큰 k에 더 높은 중요도 부여 / **pass@k 상대적 향상** : OFF 기준선 대비 개선 측정 / **가중치 합** → 정규화

Reasoning Expands The Model's Parametric Knowledge Boundary

추론이 모델의 Parametric 지식 경계를 확장한다

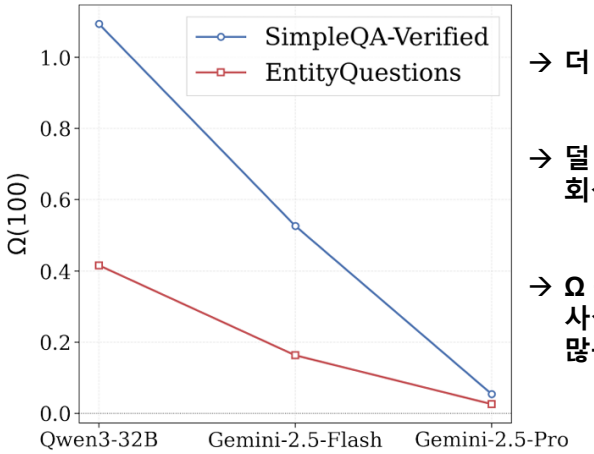

Figure 2 | Ω in all models and datasets (§2). Models organized from the most (left) to the least effective (right) in terms of pass@1.

→ 더 똑똑 모델 → 추론 없이도 Parametric 지식 효과적으로 활용

→ 덜 똑똑 모델 → 더 많은 hidden knowledge 보유 + 추론이 비효율적인 Parametric 지식 회상 보완

→ Ω 는 Simple QA > Entity Questions : Simple QA의 낮은 기준 성능은 해당 dataset의 사실들이 모델 파라미터에서 가져오기 더 어려움 → 추론이 비효율적 회상 보완할 여지 더 많음

Less Capable Models Benefit More from Reasoning

Question Complexity is a Poor Predictor of Reasoning Effectiveness

질문 복잡도는 추론 효과성의 나쁜 예측자이다

Natural hypothesis for the utility of reasoning **추론은 복잡한 다단계 질문 분해를 돕는다.**

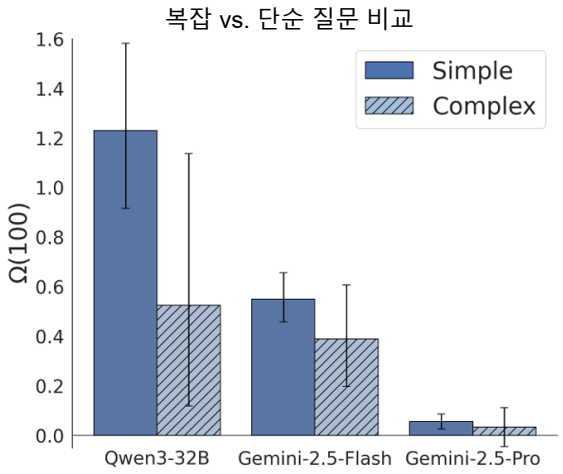

Figure 3 | Reasoning Effectiveness on different question types in `SimpleQA-Verified`, with 95% confidence intervals.

Dataset : Simple QA-Verified의 메타데이터 활용

- **Complex** : "추론 필요" 또는 "다단계" 레이블 된 질문 중 하나라도 해당
- **Simple** : 나머지 질문

→ 두 subset의 95% 신뢰 구간이 겹침

→ Gemini-2.5-Pro에서는 복잡 subset에서도 추론 이득 보장 안 됨

Complex subset에서 추론이 더 높은 한계 이득 보인다고 할 수 없음

How Reasoning Improves Parametric Recall?

- Reasoning Tokens as a Computational Buffer

가설

추론 중 추가 토큰 생성 시 모델이 추가적인 잠재 연산 수행하고 단일 순전파의 깊이 제한 우회 가능
→ R-LLM이 도달하기 어려운 Parametric 지식을 검색하기 위해 암묵적으로 이 메커니즘 활용

실험 설계

ON Dummy 변형 도입

- 모델의 원래 추론 흔적 → 의미 X 더미 시퀀스 "Let me think."로 대체
- 원래 흔적 길이와 일치하도록 반복
- 이에 조건부로 최종 답변 재생성

ON Single Dummy 변형 (통제)

- ON Dummy와 동일하지만 더미 문자열이 한 번만 등장

목적

ON/OFF 편향 통제

- 성능 차이가 확장된 계산이 아닌 훈련 데이터 불균형으로 인한 결과일 수 있음
- 두 변형 모두 추론 흔적에 의미적 내용이 없고 ON 모드로 동작 → 유일한 차이는 계산 길이

How Reasoning Improves Parametric Recall?

- Reasoning Tokens as a Computational Buffer

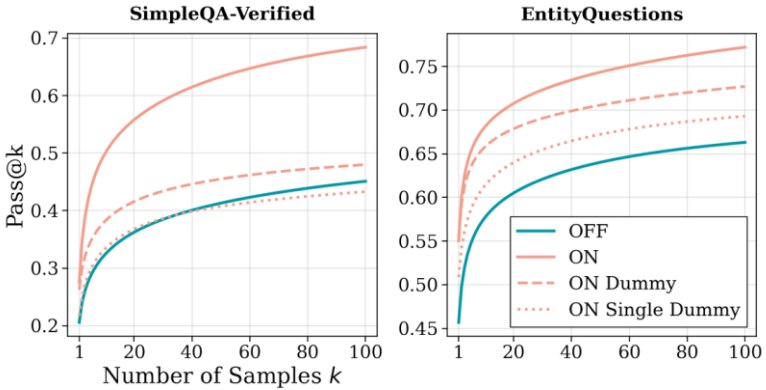

Figure 4 | Computation buffer effect on Gemini-2.5-Flash (§5.1). `ON Single Dummy` overrides the thinking trace with a short dummy sequence. `ON Dummy` does the same, but repeats the short dummy sequence to match the length of the original trace.

→ **ON Dummy : 조건부로도 OFF 대비 pass@k 실질적으로 향상시킴**

→ **Simple QA-Verified : 정확도 0.206 → 0.262 / Entity Questions : 0.457 → 0.554**

→ **ON Dummy, ON Single Dummy 사이 성능 격차**

계산량이 독립적으로 효과가 있다 할 수 있음

How Reasoning Improves Parametric Recall?

- Reasoning Tokens as a Computational Buffer

Test if more computation is always better

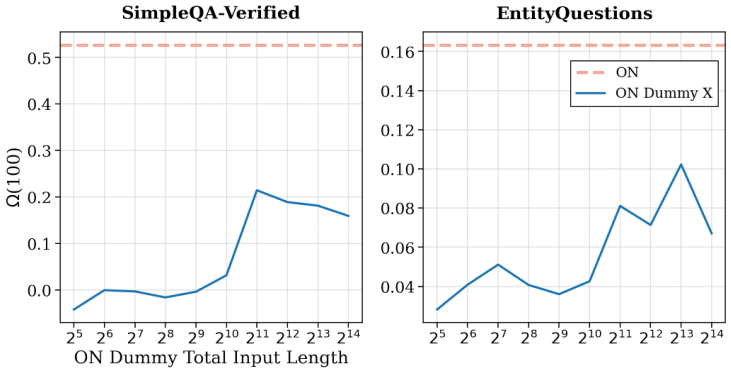

Figure 5 | Reasoning effectiveness (Equation 1) as a function of the input length in tokens when conditioning on dummy reasoning trace (see §5.1). `ON Dummy X` overrides the reasoning trace with a short dummy sequence which is repeated such that the input length will be X.

→ **비단조적 스케일링 패턴 관찰**

→ **Dummy 길이 따라 pass@k 초반에는 상향 but, 특정 지점 지나면 역효과 발생**

더 많은 계산량이 항상 좋은 건 아님

How Reasoning Improves Parametric Recall?

- Factual Priming

Hypothesis **R-LLM이 의미론적 네트워크 통해 활성화가 확산되어 관련 이웃 개념들의 검색 임계값 낮춘다.**

- 모델 생성적 자기 검색에 참여 → 관련 사실들 회상 → 답변에 대한 문맥적 다리 효과적으로 구성
- 이 메커니즘 “Factual Priming"이라고 정의

실험 설계 **LLM 프롬프트를 통해 추론 흔적에서 언급된 사실 목록 추출**

과제 **흔적이 질문의 정보 재진술 가능성** : 추론 중 도입된 사실 캡처 위해 재진술 제거

모델이 추론 중 답변 확정 지을 가능성 : 답변 드러내는 진술 필터링

변형

ON Facts : 추론 흔적을 추출된 사실 목록으로 재정의 후 답변 재생성

OFF Facts : 모델이 추론 OFF로 실행하되 사실 목록을 추가 문맥으로 제공

OFF Dummy Facts : 사실을 유사한 길이의 더미 문자열로 대체

ON Dummy Facts : 위와 동일하지만 ON 모드에서 실행

How Reasoning Improves Parametric Recall?

- Factual Priming

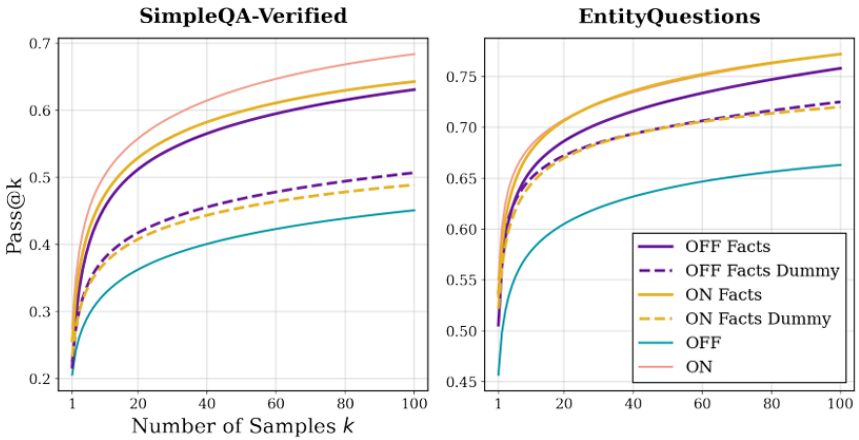

Figure 6 | Factual priming effect on Gemini-2.5-Flash (§5.2), conditioning on facts recalled during reasoning, with reasoning either OFF (OFF Facts) or ON (ON Facts).

→ 두 기준선(ON Facts, OFF Facts) 모두 더미 변형보다 상당히 뛰어남

→ 추론 비활성화해도 Facts가 도움 됨 → Facts 자체가 답변 회상에 유용

→ ON Facts가 OFF Facts보다 더 잘 수행됨 → 분포 이동에 강건 + ON 모드 양의 편향 존재 가능

→ Entity Questions에서 ON Facts가 훨씬 적은 계산으로 ON의 성능과 일치

How Reasoning Improves Parametric Recall?

- Reasoning Hallucinations Encourage Final Answer Hallucinations

추론 중 관련 사실을 회상하면 정답을 용이하게 할 수 있지만 이런 회상이 정확하다는 보장 X

실험 설계 | 각 질문과 각 추론 ON Sample에 추출된 Facts 사용하고 각각 독립적으로 검증

검증
- Gemini-2.5-Flash : 정확성 평가 및 불확실 시 기권 허용
- 인간 평가 : 정확 또는 부정확으로 분류된 사실 중 추정 검증 정확도 ~100%

분류
- **Clean traces** : 모든 중간 사실이 정확
- **Hallucinated traces** : 적어도 하나의 부정확한 사실 포함

결과
- Simple QA-Verified : Clean(41.4%) → Hallucinated(26.4%)
- Entity Questions : Clean(71.1%) → Hallucinated(32.2%)

How Reasoning Improves Parametric Recall?

- Reasoning Hallucinations Encourage Final Answer Hallucinations

질문 난이도 통제

각 Subset, 적어도 10개 흔적 포함하는 질문만 사용

두 서브셋에서 최종 답변 정확도가 동일한 정보 없는 질문 제외

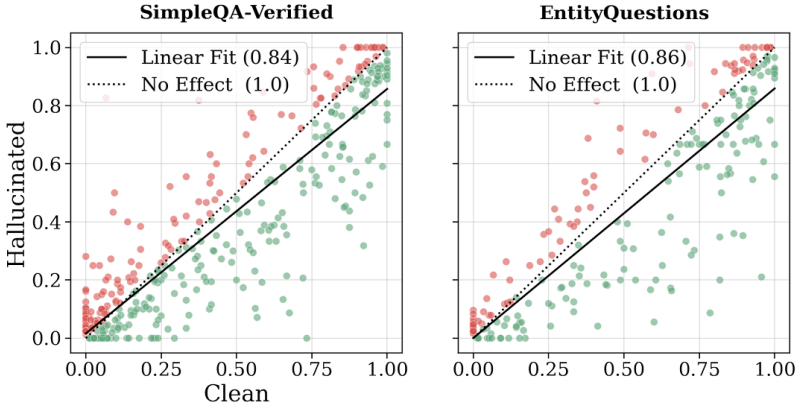

→ 회귀선 기울기
Simple QA-Verified : 0.84
Entity Questions : 0.86
→ 두 값 모두 1 미만

Figure 7 | Within-question comparison of correct final-answer rates in clean (x-axis) vs. hallucinated (y-axis) reasoning traces. Each question is one point; red examples lie above the no-effect diagonal, green below.

Hallucinated traces가 올바른 답변 예측할 가능성 낮다

How Reasoning Improves Parametric Recall?

- From Analysis to Practice: Improving Accuracy by Sampling High-Potential Traces

각 메커니즘의 실용성 평가

계산 버퍼 효과 신뢰할 수 있는 control signal X

사실적 신호 traces가 명시적 사실을 회상하는지 + 그 facts가 정확한지 감지하는 것이 중요

Strategy	SimpleQA-Verified	EntityQuestions
Regular	27.9	56.9
Only Facts	30.2 (+8.2%)	58.4 (+2.6%)
Only Correct Facts	**31.3 (+12.2%)**	**59.8 (+5.1%)**

Table 1 | Expected accuracy under test-time selection criteria based on factual recall and factual correctness.

Only Facts : 명시적으로 사실을 회상하는 흔적 유지 / Only Correct Facts : 사실을 회상하고 환각된 중간 사실이 없는 흔적 유지

Only Correct Facts 정확도 향상에 도움 됨 → process rewards (Lightman et al., 2024) 훈련으로 구현 가능

Case Studies

- The Computational Buffer Effect

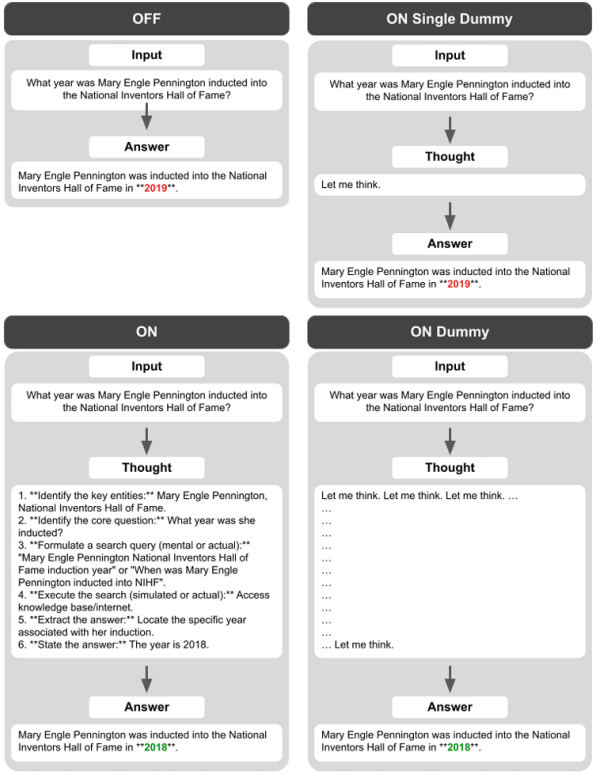

Figure 8 | Case study for the effectiveness of the computational buffer effect.

→ **OFF : 틀린 답변 예측**

→ **ON : 올바른 답변 예측(추론 흔적은 질문 재진술하고 검색 실행)**

→ **ON Dummy : 올바른 답변 예측**

→ **ON Single Dummy : 틀린 답변 예측**

모델이 정답 회상하기 위해 추가 계산 단계 必

Case Studies

- Factual Priming

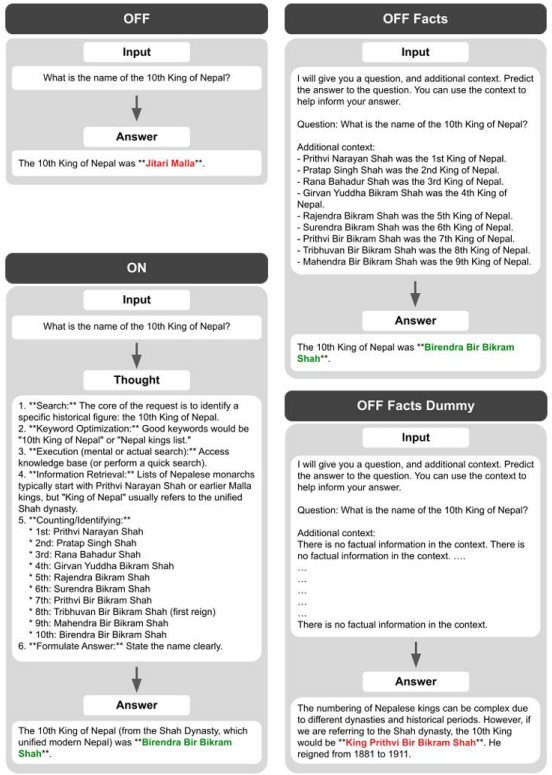

Figure 9 | Case study for the effectiveness of factual priming.

→ **OFF : 틀린 답변 예측**

→ **ON : 올바른 답변 예측**

→ **OFF Facts : 올바른 답변 예측**

→ **OFF Dummy Facts : 틀린 답변 예측**

OFF Facts 성공이 OFF 대비 증가된 계산량 때문이 아님

Conclusion

LLM의 Reasoning이 단순히 복잡한 문제를 푸는 것을 넘어
모델 내부의 Hidden Knowledge를 깨우는 메커니즘으로 기능한다는 새로운 관점 제시